

Relazione tra Magnitudine Assoluta e Redshift nei Quasar

Fabio Sucameli

2024-12-17

Abstract

I quasar, tra gli oggetti più luminosi dell'universo e alimentati da buchi neri supermassicci in accrescimento, costituiscono una straordinaria finestra sull'evoluzione cosmica. Analizzando il dataset **SDSS_QSO**, basato sul **Sloan Digital Sky Survey (SDSS)**, indaghiamo la relazione tra il **redshift**, indicatore della distanza cosmologica e dell'età dell'universo al momento dell'emissione della luce, e la **magnitudine assoluta**, misura della luminosità intrinseca del quasar. Attraverso modelli di regressione lineare, esploriamo i legami tra queste due variabili, ponendo le basi per comprendere come le proprietà dei quasar si siano evolute nel tempo cosmico.




Figure 1: Hubble Quasars - Nasa

Breve Descrizione delle Variabili

Variabile	Descrizione
SDSS	Identificativo SDSS, composto da ascensione retta (RA) e declinazione (DEC) dell'oggetto celeste.
z	Redshift, una misura della distanza cosmologica.
u_mag	Magnitudine nel filtro ultravioletto (banda u).
sig_u_mag	Errore standard della magnitudine nella banda u .
g_mag	Magnitudine nella banda verde (g).
sig_g_mag	Errore standard della magnitudine nella banda g .
r_mag	Magnitudine nella banda rossa (r).
sig_r_mag	Errore standard della magnitudine nella banda r .
i_mag	Magnitudine nella banda infrarossa (i).
sig_i_mag	Errore standard della magnitudine nella banda i .
z_mag	Magnitudine nella banda infrarossa più lontana (z).
sig_z_mag	Errore standard della magnitudine nella banda z .
FIRST	Luminosità nella banda radio, derivata dalla survey FIRST. Valore -1 indica non rilevato.
ROSAT	Luminosità nei raggi X, calcolata come logaritmo del flusso. Valore -9 indica assenza di rilevazione.
M_p	Magnitudine assoluta nella banda i , rappresenta la luminosità intrinseca del quasar.

Introduzione

Secondo la letteratura scientifica sui quasar, all'aumentare del **redshift** z , che indica oggetti situati a distanze cosmologiche maggiori, ci si aspetta una **diminuzione della magnitudine assoluta** M_p . Valori più bassi di M_p corrispondono a una **maggiore luminosità intrinseca** dell'oggetto. Questo fenomeno è coerente con il fatto che i quasar più distanti osservati tendono ad essere estremamente luminosi, altrimenti non sarebbero visibili a tali distanze.

Tuttavia, la relazione tra M_p e z può essere **influenzata da altre variabili fotometriche** e fisiche che caratterizzano i quasar. In particolare, le bande fotometriche r_mag e g_mag , frequentemente citate nella letteratura, giocano un ruolo chiave:

- r_mag : È la banda principale per la stima della magnitudine assoluta M_p , poiché misura la luminosità nella regione rossa dello spettro elettromagnetico.
- g_mag : Fornisce un'informazione complementare a r_mag , coprendo la parte blu-verde dello spettro. Questa banda è fondamentale per calcolare indici di colore come $g - r$, spesso utilizzati per comprendere le proprietà spettrali dei quasar.
- Altre variabili come **ROSAT** e **FIRST** potrebbero evidenziare emissioni energetiche peculiari, influenzando la luminosità intrinseca misurata.

Questa analisi permetterà di approfondire la conoscenza delle relazioni tra la magnitudine assoluta M_p , il redshift z e altre variabili chiave, fornendo un quadro completo delle caratteristiche fotometriche dei quasar e migliorando le previsioni sulla loro luminosità in funzione della distanza cosmologica.

Preparazione del dataset

La pulizia dei dati è una fase fondamentale per garantire un'analisi accurata e significativa. In questa sezione, descriviamo il processo di caricamento e pulizia del dataset **SDSS_QSO**, che contiene osservazioni sui

quasar, per rimuovere valori anomali, non validi o mancanti. Questo passaggio ci permette di ottenere un dataset pronto per analisi più approfondite.

Procedimento di Pulizia del Dataset

Caricamento delle librerie

```
# Caricamento delle librerie
library(dplyr)      # Per manipolare i dati
library(ggplot2)    # Per creare grafici
library(corrplot)   # Per visualizzare matrici di correlazione come heatmap
library(psych)      # Fornisce funzioni per analisi psicometriche
library(tidyr)      # Per riorganizzare i dati
library(gRim)       # Per modelli grafici
library(gridExtra)  # Per modelli grafici
library(igraph)     # Per operazioni su grafi
library(qgraph)     # Per visualizzare grafi di correlazione e reti grafiche
library(glasso)     # Per la stima di grafi con Lasso
library(bnlearn)    # Per l'apprendimento di strutture di Reti Bayesiane
```

Caricamento del Dataset Il dataset SDSS_QSO è stato caricato in R utilizzando la funzione `read.csv()`. La dimensione iniziale è stata registrata per valutare l'impatto della pulizia successiva.

```
# Caricamento del dataset
dataset <- read.csv("SDSS_QSO.csv")

# Dimensione iniziale del dataset
cat("Dimensione del dataset iniziale:", dim(dataset), "\n")
```

```
## Dimensione del dataset iniziale: 77429 15
```

```
summary(dataset)
```

```
##      SDSS              z          u_mag      sig_u_mag
## Length:77429      Min.   :0.0780      Min.   : 0.00      Min.   :0.00000
## Class :character  1st Qu.:0.9555      1st Qu.:19.09      1st Qu.:0.02800
## Mode  :character  Median :1.4820      Median :19.58      Median :0.03700
##                               Mean  :1.5375      Mean  :19.82      Mean  :0.08947
##                               3rd Qu.:1.9303      3rd Qu.:20.30      3rd Qu.:0.05500
##                               Max.   :5.4135      Max.   :26.79      Max.   :9.99900
##      g_mag      sig_g_mag      r_mag      sig_r_mag
## Min.   : 0.00      Min.   :0.00000      Min.   : 0.00      Min.   :0.00000
## 1st Qu.:18.86      1st Qu.:0.01900      1st Qu.:18.69      1st Qu.:0.01700
## Median :19.30      Median :0.02300      Median :19.12      Median :0.02000
## Mean   :19.35      Mean   :0.02653      Mean   :19.12      Mean   :0.02238
## 3rd Qu.:19.95      3rd Qu.:0.02800      3rd Qu.:19.71      3rd Qu.:0.02500
## Max.   :26.42      Max.   :1.49900      Max.   :22.54      Max.   :8.44500
##      i_mag      sig_i_mag      z_mag      sig_z_mag
## Min.   : 0.00      Min.   :0.00000      Min.   : 0.00      Min.   :0.00000
## 1st Qu.:18.58      1st Qu.:0.01800      1st Qu.:18.48      1st Qu.:0.03300
## Median :18.99      Median :0.02200      Median :18.91      Median :0.04500
## Mean   :18.97      Mean   :0.02464      Mean   :18.88      Mean   :0.05563
## 3rd Qu.:19.56      3rd Qu.:0.02800      3rd Qu.:19.45      3rd Qu.:0.06800
## Max.   :22.36      Max.   :6.44300      Max.   :22.68      Max.   :9.99900
```

##	FIRST	ROSAT	Mp
##	Min. : -1.00	Min. : -9.000	Min. : -30.27
##	1st Qu.: 0.00	1st Qu.: -9.000	1st Qu.: -26.42
##	Median : 0.00	Median : -9.000	Median : -25.59
##	Mean : 1.06	Mean : -8.599	Mean : -25.41
##	3rd Qu.: 0.00	3rd Qu.: -9.000	3rd Qu.: -24.57
##	Max. : 16.40	Max. : 0.139	Max. : -22.00

Descrizione del Processo di Pulizia

Rimozione di Valori Anomali

Per garantire che i dati siano coerenti e rappresentativi, sono stati eliminati valori considerati anomali. In particolare:

- **Magnitudine Assoluta (M_p):**
 - Sono stati rimossi i valori fuori dal range $[-30, 0]$, poiché rappresentano anomalie o errori nei dati.
- **Redshift (z):**
 - Sono stati esclusi i valori minori o uguali a 0, in quanto non significativi o non fisicamente validi per l'analisi dei quasar.

Rimozione di Valori Non Validi

Alcune variabili del dataset includono valori che indicano mancanza di rilevazione o misurazioni non valide:

- **ROSAT:**
 - La variabile ROSAT rappresenta la luminosità nei raggi X.
 - Il valore -9 è stato utilizzato per indicare l'assenza di emissioni rilevate.
 - Queste osservazioni sono state rimosse per evitare distorsioni nell'analisi.
- **FIRST:**
 - La variabile FIRST rappresenta la luminosità radio.
 - I valori negativi, come -1 , indicano che il quasar non è stato rilevato nella survey radio.
 - Questi valori sono stati esclusi dal dataset per focalizzarsi solo su oggetti con misurazioni effettive.

Rimozione di Valori Mancanti

Le righe contenenti valori mancanti in qualsiasi variabile sono state rimosse per garantire che il dataset sia completo e pronto per l'analisi. Questo è stato effettuato utilizzando la funzione `na.omit()`.

```
# Pulizia dei dati
dataset_cleaned <- dataset %>%
  filter(Mp > -30 & Mp < 0 & z > 0) %>%
  filter(ROSAT != -9, FIRST >= 0)

# Rimuove valori mancanti
dataset_cleaned <- na.omit(dataset_cleaned)

cat("Dimensione del dataset dopo la pulizia:", dim(dataset_cleaned), "\n")

## Dimensione del dataset dopo la pulizia: 3918 15
```

Analisi e Gestione della Variabile SDSS

La colonna **SDSS** nel dataset rappresenta una designazione celeste standard utilizzata per indicare la posizione di un oggetto astronomico. Questa variabile è costituita da valori come che combinano due coordinate spaziali:

- **Ascensione Retta (RA)**: corrisponde alla longitudine celeste e indica la posizione angolare di un oggetto rispetto al punto di riferimento (l'equinizio).
- **Declinazione (DEC)**: corrisponde alla latitudine celeste e misura la distanza angolare dall'equatore celeste.

Per avere un dataset più pulito, in formato numerico, è stato necessario convertire la variabile espressa in formato stringa in due colonne numeriche: RA e DEC.

Identificazione delle Colonne Non Numeriche

Iniziamo identificando tutte le colonne non numeriche nel dataset per determinarne il contenuto.

```
non_numeric_vars <- names(dataset_cleaned)[!sapply(dataset_cleaned, is.numeric)]
cat("Colonne non numeriche:\n", non_numeric_vars, "\n")
```

```
## Colonne non numeriche:
## SDSS
```

Questo passaggio ha rivelato che la colonna SDSS è l'unica variabile non numerica, contenente valori che necessitano di elaborazione.

Separazione della Variabile SDSS in RA e DEC

Per utilizzare le coordinate equatoriali nelle analisi, è stato necessario dividere la colonna **SDSS** in due colonne distinte: RA (Ascensione Retta) e DEC (Declinazione).

Dettagli dell'Operazione

1. **Separazione con [+ -]**:
 - Il separatore [+ -] viene utilizzato per identificare sia il segno + sia il segno - all'interno della stringa.
 - La colonna **SDSS** è stata divisa in due parti:
 - RA: valori contenuti prima del separatore.
 - DEC: valori contenuti dopo il separatore.
2. **Aggiunta del segno al DEC**:
 - È stata creata una colonna temporanea chiamata **DEC_sign** per registrare il segno positivo o negativo (+/-) basato sul contenuto della stringa.
 - Questo segno è stato successivamente aggiunto al valore numerico della colonna DEC per mantenere la coerenza.
3. **Rimozione della Colonna Originale SDSS** Dopo aver separato e convertito la colonna SDSS in RA e DEC, la colonna originale non è più necessaria e può essere eliminata.

Il codice sottostante mostra i passaggi implementati per effettuare questa operazione:

```
# Divisione SDSS gestendo sia il separatore "+" che "-"
dataset_cleaned <- dataset_cleaned %>%
  separate(SDSS, into = c("RA", "DEC"), sep = "[+ -]", remove = FALSE, fill = "right") %>%
  mutate(
    DEC_sign = ifelse(grepl("\\+", SDSS), "+", "-"),
    DEC = paste0(DEC_sign, DEC)
  ) %>%
  select(-DEC_sign)
```

```
# Conversione RA e DEC in numeri
dataset_cleaned <- dataset_cleaned %>%
  mutate(
    RA = as.numeric(RA),
    DEC = as.numeric(DEC)
  )

# Rimozione della colonna SDSS
dataset_cleaned <- dataset_cleaned %>% select(-SDSS)

cat("Colonna SDSS rimossa. Dimensione attuale del dataset:", dim(dataset_cleaned), "\n")

## Colonna SDSS rimossa. Dimensione attuale del dataset: 3918 16
```

Analisi preliminare e rimozione degli outliers

L'obiettivo iniziale è stato esplorare e comprendere la relazione tra le variabili **Redshift** (z) e **Magnitudine Assoluta** (M_p), con particolare attenzione alla presenza di **outliers**. Gli outliers rappresentano valori anomali che possono influenzare negativamente sia le visualizzazioni grafiche che i risultati delle analisi statistiche.

Visualizzazione dei dati prima della rimozione degli outliers


Prima della rimozione degli outliers, sono state generate alcune rappresentazioni grafiche per comprendere la struttura dei dati:

- **Scatterplot z vs M_p :**

È stato creato un grafico di dispersione per osservare la relazione tra il **Redshift** (z) e la **Magnitudine Assoluta** (M_p).


```
# Scatterplot z vs Mp (prima)
ggplot(dataset, aes(x = z, y = Mp)) +
  geom_point(alpha = 0.5, color = "blue") +
  theme_minimal() +
  labs(title = "Prima della rimozione degli outliers",
       x = "Redshift (z)",
       y = "Magnitudine Assoluta (Mp)")
```

Prima della rimozione degli outliers



- **Boxplot di M_p e di z :** È stato costruito un boxplot della variabile sia per la variabile M_p che per la variabile z per individuare visivamente i valori anomali oltre i confini interquartilici.

```
boxplot_b_Mp <- ggplot(dataset, aes(y = Mp)) +  
  geom_boxplot(fill = "lightblue", alpha = 0.6) +  
  theme_minimal() +  
  labs(title = "Magnitudine Assoluta (Mp)",  
        y = "Magnitudine Assoluta (Mp)")  
  
boxplot_b_z <- ggplot(dataset, aes(y = z)) +  
  geom_boxplot(fill = "lightblue", alpha = 0.6) +  
  theme_minimal() +  
  labs(title = " Redshift (z)",  
        y = "Redshift (z)")  
  
grid.arrange(boxplot_b_Mp, boxplot_b_z, nrow = 1)
```



Rimozione degli outliers con la regola IQR

La rimozione degli outliers è stata effettuata utilizzando la **regola dell'Interquartile Range (IQR)**. I passaggi seguiti sono stati:

1. Calcolo dell'IQR:

L'IQR è definito come la differenza tra il terzo quartile ($Q3$) e il primo quartile ($Q1$):

$$IQR = Q3 - Q1$$

2. Definizione dei limiti:

Per identificare i valori anomali, sono stati calcolati i limiti inferiore e superiore:

- Lower Bound = $Q1 - 1.5 \times IQR$
- Upper Bound = $Q3 + 1.5 \times IQR$

3. Applicazione dei filtri:

I dati sono stati filtrati eliminando i valori di Mp e z al di fuori di questi limiti.

```
Q1_Mp <- quantile(dataset_cleaned$Mp, 0.25)
Q3_Mp <- quantile(dataset_cleaned$Mp, 0.75)
IQR_Mp <- Q3_Mp - Q1_Mp

lower_bound_Mp <- Q1_Mp - 1.5 * IQR_Mp
upper_bound_Mp <- Q3_Mp + 1.5 * IQR_Mp

Q1_z <- quantile(dataset_cleaned$z, 0.25)
Q3_z <- quantile(dataset_cleaned$z, 0.75)
```

```

IQR_z <- Q3_z - Q1_z

lower_bound_z <- Q1_z - 1.5 * IQR_z
upper_bound_z <- Q3_z + 1.5 * IQR_z

dataset_cleaned <- dataset_cleaned %>%
  filter(Mp >= lower_bound_Mp & Mp <= upper_bound_Mp) %>%
  filter(z >= lower_bound_z & z <= upper_bound_z)

cat("Dimensione del dataset dopo rimozione outliers:", dim(dataset_cleaned), "\n")

## Dimensione del dataset dopo rimozione outliers: 3713 16

```

Visualizzazione dei dati dopo la rimozione degli outliers

Dopo la pulizia dei dati, sono state riprodotte le stesse rappresentazioni grafiche per confrontare i risultati:


```

# Creazione dei grafici
boxplot_Mp <- ggplot(dataset_cleaned, aes(y = Mp)) +
  geom_boxplot(fill = "orange", alpha = 0.6) +
  theme_minimal() +
  labs(title = "Magnitudine Assoluta (Mp)",
       y = "Magnitudine Assoluta (Mp)")

boxplot_z <- ggplot(dataset_cleaned, aes(y = z)) +
  geom_boxplot(fill = "orange", alpha = 0.6) +
  theme_minimal() +
  labs(title = "Redshift (z)",
       y = "Redshift (z)")

grid.arrange(boxplot_Mp, boxplot_z, nrow = 1)

```



Casi estremi:

Dopo la rimozione degli outliers basati sulla **regola IQR**, l'analisi si è concentrata sugli **outliers fisicamente plausibili**. In particolare, abbiamo considerato valori di **Magnitudine Assoluta** (M_p) e **Redshift** (z) che, pur essendo estremi, potrebbero corrispondere a oggetti reali con caratteristiche particolari piuttosto che a errori di misura.

Criteri di identificazione:

Gli outliers fisicamente plausibili sono stati identificati secondo i seguenti criteri:

- **$M_p < -28$** : Oggetti con una magnitudine assoluta estremamente negativa, indicativi di sorgenti molto luminose.
- **$z > 3.5$** : Valori di Redshift molto alti, che corrispondono a oggetti estremamente distanti.

Analisi quantitativa

- È stato calcolato il numero di osservazioni che soddisfano almeno uno dei criteri di **$M_p < -28$** o **$z > 3.5$** .
- La **percentuale** di questi outliers rispetto al dataset originale è stata determinata per comprendere l'impatto sul campione totale.

```
# Identifica outliers "fisicamente plausibili" in  $M_p$  e  $z$ 
potentially_significant <- dataset_cleaned %>%
  filter( $M_p < -28$  |  $z > 3.5$ )
```

```
cat("Outliers fisicamente significativi (Mp < -28 o z > 3.5):",
    nrow(potentially_significant), "\n")
```

```
## Outliers fisicamente significativi (Mp < -28 o z > 3.5): 12
```

```
# Percentuale di outliers significativi rispetto al totale
```

```
total_data <- nrow(dataset)
```

```
significant_outliers <- nrow(potentially_significant)
```

```
percent_outliers <- (significant_outliers / total_data) * 100
```

```
cat("Percentuale di outliers significativi (Mp < -28 o z > 3.5):",
    round(percent_outliers, 2), "%\n")
```


```
## Percentuale di outliers significativi (Mp < -28 o z > 3.5): 0.02 %
```

I valori identificati non sono stati rimossi dal dataset poiché, nonostante siano considerati **outliers estremi**, possono rappresentare oggetti astronomici particolarmente luminosi o distanti, come **quasar** ad alta luminosità.

```
# Scatterplot con evidenza degli outliers
```

```
ggplot(dataset_cleaned, aes(x = z, y = Mp)) +
  geom_point(alpha = 0.5, color = "blue") +
  geom_point(data = potentially_significant, aes(x = z, y = Mp), color = "red", size = 3) +
  theme_minimal() +
  labs(title = "Scatterplot con evidenza degli outliers significativi",
       x = "Redshift (z)", y = "Magnitudine Assoluta (Mp)")
```

Scatterplot con evidenza degli outliers significativi



La visualizzazione permette di distinguere chiaramente questi oggetti e sottolineare la loro natura unica rispetto al resto del campione.

Rimozione delle colonne RA e DEC:

Dal momento che l'obiettivo di questo studio non è quello di studiare la distribuzione spaziale dei quasar per analisi geografiche, le variabili RA (Ascensione Retta) e DEC (Declinazione) sono state rimosse dal dataset. La dimensione del dataset è stata aggiornata di conseguenza.

```
dataset_cleaned <- dataset_cleaned %>%  
  select(-RA, -DEC)  
  
cat("Dimensione del dataset dopo la rimozione di RA e DEC:", dim(dataset_cleaned), "\n")  
  
## Dimensione del dataset dopo la rimozione di RA e DEC: 3713 14
```

Standardizzazione delle variabili:

Tutte le variabili numeriche selezionate sono state **standardizzate**. Questo passaggio è stato eseguito per portare tutte le variabili su una scala comparabile, riducendo l'influenza di variabili con unità o ordini di grandezza differenti.

- Per ogni variabile numerica, è stato calcolato lo **z-score** utilizzando la formula:

$$z = \frac{x - \mu}{\sigma}$$

dove μ è la media della variabile e σ è la sua deviazione standard.

- Il dataset standardizzato è stato salvato come `dataset_standardized`, che ha sostituito il dataset originale (`dataset_cleaned`) per le analisi successive.

Esempio delle prime righe del dataset standardizzato:

```
numerical_vars <- dataset_cleaned  
  
dataset_standardized <- as.data.frame(scale(numerical_vars))  
  
print(head(dataset_standardized))  
  
##           z      u_mag  sig_u_mag      g_mag  sig_g_mag      r_mag  
## 1 -0.4058448 -0.3743797 -0.13397836 -0.40945383 -0.1609737 -0.28206697  
## 2 -0.9244036  0.1564669 -0.01462003  0.13283132 -0.0676567 -0.04993739  
## 3  2.6566562  0.9935984  0.51055662  1.09974307  0.4922452  0.95107319  
## 4 -1.0776971 -0.4497073 -0.20559336 -0.42981780 -0.1609737 -0.54812910  
## 5 -0.4813685  0.7448751  0.34345496  0.43376563  0.2122943  0.37344844  
## 6  0.2668498  0.0747435 -0.08623503 -0.02102984 -0.1609737  0.03566521  
##      sig_r_mag      i_mag  sig_i_mag      z_mag  sig_z_mag      FIRST  
## 1 -0.05657411 -0.24588521 -0.18741719 -0.1694766 -0.195588548 -0.458201  
## 2 -0.22878242 -0.02634632 -0.14438327 -0.3658854 -0.328734109 -0.458201  
## 3  0.18451751  0.84098688  0.02775242  1.0214964  0.891766875 -0.458201  
## 4  0.21895917 -0.57287447 -0.20893415 -0.5450791 -0.373115963 -0.458201  
## 5  0.08119253  0.25580753  0.09230330  0.1576106  0.004129795 -0.458201  
## 6 -0.15989910  0.14526506  0.07078634  0.2303836  0.092893503 -0.458201  
##      ROSAT      Mp  
## 1 -0.6279670 -0.1001457  
## 2 -0.2642249  0.9552651  
## 3 -0.8693887 -1.1813702  
## 4  0.3634716  0.7989080  
## 5 -0.2771007  0.4729181
```


```
## 6 -0.3189472 -0.4615372
```

Visualizzazione della distribuzione delle variabili:


È stato creato un **plot di istogrammi** per ogni variabile standardizzata per analizzare la distribuzione delle variabili dopo la standardizzazione.

```
par(mfrow = c(3, 3))

for (var in colnames(dataset_standardized)) {
  hist(dataset_standardized[[var]],
    main = paste( var),
    xlab = var, col = "gray", border = "black")
}
```



```
par(mfrow = c(1, 1))
```



Studio sulle distribuzioni

- **z (Redshift)** e **ROSAT (luminosità X-ray)** mostrano distribuzioni **più gaussiane** o simmetriche. La tendenza centrale è evidente, con code moderate attorno ai valori medi.
- La distribuzione di **Mp** è **asimmetrica negativa**: i valori si accumulano vicino alle magnitudini più luminose (valori negativi di Mp). La coda lunga verso valori meno luminosi è una caratteristica attesa, poiché i quasar più luminosi sono meno numerosi.
- Le variabili di incertezza (**sig_x_mag**) mostrano una coda lunga, indicando che pochi oggetti hanno errori di misura elevati, mentre la maggior parte ha errori ridotti.
- Le variabili nelle Bande Fotometriche (**u_mag, g_mag, r_mag, i_mag**) hanno distribuzioni sono leggermente asimmetriche, suggerendo che la maggior parte dei quasar ha luminosità più basse, mentre quelli estremamente luminosi sono meno comuni.

La **standardizzazione** ha permesso di ottenere variabili comparabili, senza alterare la forma delle distribuzioni, fornendo una base solida per le successive analisi sulla relazione tra **Mp** e **z**.

Analisi della Multicollinearità e Studio del Modello

In questo contesto la **multicollinearità** potrebbe rappresentare un problema rilevante. Questo fenomeno si verifica quando variabili predittive, come le magnitudini nelle diverse bande fotometriche, sono fortemente correlate tra loro.

Obiettivo

Il processo include:

- 1) Identificazione delle variabili fortemente correlate.
- 2) Analisi delle variabili ridondanti.
- 3) Valutazione dell'impatto della semplificazione sul modello e sui risultati.

Identificazione della Multicollinearità

Per identificare variabili altamente correlate, calcoliamo una matrice di correlazione e analizziamo le coppie di variabili con correlazione superiore a una soglia di 0.9.

```
# Modelli preliminari con tutte le variabili
lm_model_full_mp <- lm(Mp ~ ., data = dataset_standardized)

# Matrice di correlazione per identificare multicollinearità
numeric_vars <- select(dataset_standardized, where(is.numeric))
cor_matrix <- cor(numeric_vars, use = "complete.obs")

# Soglia per identificare correlazioni elevate
correlation_threshold <- 0.9

high_corr_pairs <- which(abs(cor_matrix) > correlation_threshold, arr.ind = TRUE)
high_corr_pairs <- high_corr_pairs[high_corr_pairs[, 1] < high_corr_pairs[, 2], ]

# Variabili collineari identificate
collinear_vars <- unique(colnames(cor_matrix)[high_corr_pairs[, 2]])
cat("\nVariabili collineari identificate:\n")

##
## Variabili collineari identificate:
print(collinear_vars)

## [1] "g_mag"      "r_mag"      "i_mag"      "sig_i_mag" "z_mag"
```

Analisi delle Variabili Ridondanti

Rimuoviamo da un dataset provvisorio le variabili ridondanti identificate dalla matrice di correlazione.

```
dataset_no_collinear <- dataset_standardized %>% select(-all_of(collinear_vars))
```

Confronto dei Risultati

Confrontiamo graficamente le matrici di correlazione prima e dopo la rimozione delle variabili ridondanti.

```
# Confronto grafico delle matrici di correlazione
par(mfrow = c(1, 2), mar = c(5, 5, 5, 5))

# Matrice di correlazione prima della rimozione
corrplot(cor_matrix, method = "color", type = "upper",
          tl.col = "black", tl.srt = 45, tl.cex = 0.8,
          main = "Prima della Rimozione", mar = c(0, 0, 2, 0))


# Matrice di correlazione dopo la rimozione
cor_matrix_cleaned <- cor(select(dataset_no_collinear, where(is.numeric)),
```

```


use = "complete.obs")
corrplot(cor_matrix_cleaned, method = "color", type = "upper",
         tl.col = "black", tl.srt = 45, tl.cex = 0.8,
         main = "Dopo la Rimozione", mar = c(0, 0, 2, 0))

```

Prima della Rimozione



Dopo la Rimozione



Prima della Rimozione

Nel grafico della matrice di correlazione prima della rimozione, si osservano numerose relazioni con valori di correlazione elevata tra variabili. Ad esempio

- Le bande fotometriche come **u_mag**, **g_mag**, **r_mag**, **i_mag**, e **z_mag** mostrano correlazioni molto alte tra loro, con valori prossimi o superiori a 0.9.
- Variabili come **sig_r_mag** e **sig_i_mag** evidenziano correlazioni significative, indicando una possibile ridondanza.

Queste correlazioni elevate suggeriscono che alcune variabili sono ridondanti, rappresentando informazioni sovrapposte che potrebbero complicare l'analisi.

Dopo la Rimozione

Nel grafico della matrice di correlazione dopo la rimozione delle variabili ridondanti (**g_mag**, **r_mag**, **i_mag**, **sig_r_mag**, **z_mag**): - Le correlazioni elevate tra variabili simili sono state eliminate, riducendo la complessità del modello.

Test del Rapporto di Verosimiglianza

Questo test verifica se l'eliminazione delle variabili collineari comporta una perdita significativa di informazione nei modelli.

```
# Test del rapporto di verosimiglianza per Mp
lm_model_reduced_mp <- lm(Mp ~ ., data = dataset_no_collinear)
logLik_full_mp <- logLik(lm_model_full_mp)
logLik_reduced_mp <- logLik(lm_model_reduced_mp)
likelihood_ratio_mp <- -2 * (logLik_reduced_mp - logLik_full_mp)
df_mp <- attr(logLik_full_mp, "df") - attr(logLik_reduced_mp, "df")
p_value_lrt_mp <- pchisq(likelihood_ratio_mp, df = df_mp, lower.tail = FALSE)
cat("\nTest del Rapporto di Verosimiglianza per variabili collineari (Mp):\n")

##
## Test del Rapporto di Verosimiglianza per variabili collineari (Mp):
cat("Likelihood Ratio Statistic (Mp):", likelihood_ratio_mp, "\n")

## Likelihood Ratio Statistic (Mp): 965.0221
cat("Gradi di Libertà (Mp):", df_mp, "\n")

## Gradi di Libertà (Mp): 5
cat("p-value (Mp):", p_value_lrt_mp, "\n")

## p-value (Mp): 2.244358e-206
if ( p_value_lrt_mp > 0.05) {
  dataset_standardized <- dataset_no_collinear
  cat("\nLe variabili collineari non sono significative e vengono rimosse dal dataset.\n")
} else {
  cat("\nLe variabili collineari sono significative e non vengono rimosse dal dataset.\n")
}

##
## Le variabili collineari sono significative e non vengono rimosse dal dataset.
# Dimensione finale del dataset
cat("\nDimensione finale del dataset:", dim(dataset_standardized), "\n")

##
## Dimensione finale del dataset: 3713 14
```

Interpretazione complessiva

Dopo aver eseguito il test del rapporto di verosimiglianza sui modelli ridotti e completi, sono emersi risultati significativi che evidenziano l'importanza delle variabili collineari nei modelli completi. Questo implica che le variabili collineari, sebbene ridondanti, apportano informazioni utili al modello e per questo vengono mantenute attualmente.

Modellazione Grafica

Questa sezione presenta la prima parte dell'analisi, incentrata sull'esplorazione delle relazioni tra le variabili incluse nel dataset standardizzato. Per questa analisi, si assume che ogni nodo X_i segua una distribuzione multi-normale:

$$X_i \sim \mathcal{N}(\mu, \Sigma)$$

Modelli Grafici Gaussiani Non Orientati

Per costruire il modello grafico non orientato, abbiamo calcolato la **matrice di concentrazione** ($K = \Sigma^{-1}$), che ci permette di identificare le dipendenze condizionali dirette tra le variabili. Successivamente, è stata derivata la **matrice delle correlazioni parziali**, che fornisce informazioni sulla forza delle relazioni dirette tra le variabili, eliminando l'effetto delle altre variabili.

La rappresentazione grafica risultante permette di evidenziare:

- Relazioni condizionali dirette tra variabili;
- Elementi che presentano valori vicini allo zero nella matrice di concentrazione, suggerendo indipendenza condizionale.

Questo approccio aiuta a semplificare la complessità del modello e a focalizzarsi sulle connessioni rilevanti. L'obiettivo principale è comprendere la relazione tra le variabili di interesse Mp e z e il ruolo delle altre variabili nel mediare queste relazioni.

```
S_data <- cov.wt(dataset_standardized, method = "ML")$cov
K_data <- solve(S_data)
PC_data <- cov2pcor(S_data)
diag(PC_data) <- 1

cat("Matrice di Concentrazione (x100):\n")
```

```
## Matrice di Concentrazione (x100):
```

```
print(round(100 * K_data, 2))
```

```
##           z      u_mag sig_u_mag      g_mag sig_g_mag      r_mag sig_r_mag
## z          756.26  582.09  -112.70 -1054.01    95.74   408.22   268.11
## u_mag       582.09 6154.62  -882.63 -5303.14   124.15 -1199.33    -5.30
## sig_u_mag  -112.70 -882.63   246.28   680.54   -23.03    86.59     3.85
## g_mag      -1054.01 -5303.14   680.54  9904.51  -279.71 -6082.33   -132.78
## sig_g_mag   95.74   124.15   -23.03  -279.71   553.98    33.11   -272.55
## r_mag       408.22 -1199.33    86.59 -6082.33    33.11 17881.96   -348.03
## sig_r_mag   268.11    -5.30     3.85  -132.78  -272.55  -348.03  2631.01
## i_mag       15.37  571.98  -12.71   430.81   -61.02 -6480.98    146.16
## sig_i_mag  -97.11  -68.38   27.18   162.33   -16.79   196.43  -1845.50
## z_mag      -89.67  -34.32   85.43  1112.92   179.95 -4286.87    336.47
## sig_z_mag  -305.18    2.24  -30.83   261.58  -236.51    97.20   -584.16
## FIRST       10.36  -82.86   13.57    5.04     8.14   -20.39    22.34
## ROSAT       122.38  205.44  -31.39  -169.26   -17.56  -106.75    11.58
## Mp          634.84  567.83  -97.72  -804.06   109.18  -543.68   257.92
##           i_mag sig_i_mag      z_mag sig_z_mag  FIRST   ROSAT      Mp
## z          15.37  -97.11  -89.67  -305.18  10.36  122.38  634.84
## u_mag       571.98  -68.38  -34.32    2.24 -82.86  205.44  567.83
## sig_u_mag  -12.71   27.18   85.43  -30.83  13.57  -31.39  -97.72
## g_mag       430.81  162.33  1112.92   261.58   5.04 -169.26 -804.06
## sig_g_mag  -61.02  -16.79  179.95  -236.51   8.14  -17.56  109.18
## r_mag      -6480.98   196.43 -4286.87    97.20 -20.39 -106.75 -543.68
## sig_r_mag   146.16 -1845.50  336.47  -584.16  22.34   11.58  257.92
## i_mag       7395.27 -113.49 -1862.81    48.47  25.54  122.11  144.78
## sig_i_mag  -113.49  1785.30 -154.80   145.99 -16.92    1.80 -101.33
## z_mag      -1862.81  -154.80  5125.65  -431.93  66.66  -19.79  487.30
```

```
## sig_z_mag      48.47      145.99 -431.93      771.43 -18.18      2.22 -304.60
## FIRST          25.54      -16.92      66.66      -18.18 109.56     -19.34   34.74
## ROSAT          122.11       1.80     -19.79       2.22 -19.34    157.85   71.32
## Mp             144.78     -101.33    487.30     -304.60  34.74     71.32   731.56

cat("Matrice di Correlazione Parziale (x100):\n")

## Matrice di Correlazione Parziale (x100):

print(round(100 * PC_data, 2))

##              z  u_mag sig_u_mag  g_mag sig_g_mag  r_mag sig_r_mag  i_mag
## z           100.00 -26.98      26.12  38.51     -14.79 -11.10     -19.01  -0.65
## u_mag       -26.98 100.00      71.69  67.92      -6.72  11.43       0.13  -8.48
## sig_u_mag    26.12 71.69     100.00 -43.57      6.23  -4.13      -0.48   0.94
## g_mag        38.51 67.92     -43.57 100.00     11.94  45.70       2.60  -5.03
## sig_g_mag   -14.79 -6.72      6.23 11.94     100.00 -1.05     22.58   3.01
## r_mag       -11.10 11.43     -4.13 45.70     -1.05 100.00       5.07  56.36
## sig_r_mag   -19.01 0.13      -0.48 2.60     22.58 5.07     100.00  -3.31
## i_mag       -0.65 -8.48      0.94 -5.03      3.01 56.36     -3.31 100.00
## sig_i_mag    8.36 2.06      -4.10 -3.86      1.69 -3.48     85.15   3.12
## z_mag        4.55 0.61      -7.60 -15.62     -10.68 44.78     -9.16  30.26
## sig_z_mag    39.96 -0.10      7.07 -9.46      36.18 -2.62     41.00  -2.03
## FIRST        -3.60 10.09     -8.26 -0.48      -3.30 1.46     -4.16  -2.84
## ROSAT       -35.42 -20.84     15.92 13.54      5.94 6.35     -1.80 -11.30
## Mp          -85.35 -26.76     23.02 29.87     -17.15 15.03     -18.59  -6.22
##              sig_i_mag  z_mag sig_z_mag  FIRST  ROSAT  Mp
## z              8.36   4.55      39.96  -3.60 -35.42 -85.35
## u_mag          2.06   0.61      -0.10 10.09 -20.84 -26.76
## sig_u_mag      -4.10  -7.60      7.07 -8.26 15.92 23.02
## g_mag          -3.86 -15.62     -9.46 -0.48 13.54 29.87
## sig_g_mag      1.69 -10.68     36.18 -3.30 5.94 -17.15
## r_mag          -3.48 44.78     -2.62 1.46 6.35 15.03
## sig_r_mag      85.15  -9.16     41.00 -4.16 -1.80 -18.59
## i_mag          3.12 30.26     -2.03 -2.84 -11.30  -6.22
## sig_i_mag     100.00  5.12     -12.44 3.83  -0.34  8.87
## z_mag          5.12 100.00     21.72 -8.90  2.20 -25.17
## sig_z_mag     -12.44 21.72     100.00 6.25  -0.63 40.55
## FIRST          3.83  -8.90      6.25 100.00 14.71 -12.27
## ROSAT         -0.34  2.20     -0.63 14.71 100.00 -20.99
## Mp            8.87 -25.17     40.55 -12.27 -20.99 100.00
```

Introduzione alla Procedura Backward

Nel contesto dell'analisi del dataset sui quasar, abbiamo scelto di mantenere le variabili collineari iniziali per evitare la perdita di informazioni potenzialmente rilevanti. Tuttavia, questa decisione richiede un approccio mirato per gestire in modo efficiente il problema della sovrabbondanza di variabili nel modello, bilanciando complessità e significatività statistica.

Questa procedura ci permette di identificare le variabili esplicative più significative per spiegare le relazioni con Mp. In particolare ci permette di:

1. **Preservare inizialmente tutte le informazioni disponibili:** Partendo dal modello completo, si evita il rischio di eliminare prematuramente variabili che potrebbero rivelarsi significative in combinazione

con altre.

2. **Valutare l'importanza di ogni variabile:** La procedura elimina solo le variabili che dimostrano di non contribuire in modo significativo al modello, permettendo così di identificare un sottoinsieme di predittori rilevanti.
3. **Equilibrare complessità e capacità predittiva:** Riducendo il modello in modo iterativo, si ottiene una rappresentazione parsimoniosa, mantenendo però la capacità di catturare le relazioni principali tra le variabili.

Descrizione della Procedura

In questa sezione è stata applicata la **procedura Stepwise Backward** per la selezione di modelli utilizzando i criteri di **AIC (Akaike Information Criterion)** e **BIC (Bayesian Information Criterion)**. L'obiettivo è ridurre la complessità del modello, mantenendo solo le interazioni più significative tra le variabili.

Modello Saturato: - È stato inizializzato un **modello saturato** che include tutte le interazioni tra le variabili presenti nel dataset.

```
sat_model <- cmod(~ .^., data = dataset_standardized)
```

Procedura Stepwise Backward:

Viene applicata una procedura iterativa che rimuove le interazioni meno significative, ottimizzando il modello con riferimento ai seguenti criteri:


- **AIC:** Minimizza l'informazione persa bilanciando la complessità e la qualità di adattamento del modello.
- **BIC:** Introduce una penalizzazione maggiore per la complessità del modello, privilegiando modelli più semplici.

```
aic_backward <- stepwise(cmod(~ .^., data = dataset_standardized),  
                        direction = "backward", k = 2)  
  
bic_backward <- stepwise(cmod(~ .^., data = dataset_standardized),  
                        direction = "backward", k = log(nrow(dataset_standardized)))
```

Visualizzazione dei Grafi: - I grafi ottenuti dopo la selezione sono stati visualizzati:


```
AIC_graph <- aic_backward$modelinfo$ug  
BIC_graph <- bic_backward$modelinfo$ug  
V(AIC_graph)$name <- aic_backward$varNames  
V(BIC_graph)$name <- bic_backward$varNames  
  
plot_graph <- function(graph, title, color) {  
  plot(graph, main = title,  
        vertex.size = 30, vertex.label.cex = 0.8,  
        vertex.color = color, edge.color = "gray50")  
}  
  
plot_graph(AIC_graph, "Grafo Selezionato da AIC", "lightblue")
```

Grafo Selezionato da AIC



```
plot_graph(BIC_graph, "Grafo Selezionato da BIC", "lightgreen")
```

Grafo Selezionato da BIC



Conteggio degli archi per AIC e BIC

```
count_edges <- function(model) {
  graph <- model$modelinfo$ug
  return(length(E(graph)))
}
```

```
num_edges_aic <- count_edges(aic_backward)
cat("Numero di archi nel grafo AIC:", num_edges_aic, "\n")
```

```
## Numero di archi nel grafo AIC: 84
```

- Il **grafo AIC** presenta il numero più elevato di archi, indicando un modello più complesso con un maggior numero di connessioni tra le variabili.

```
num_edges_bic <- count_edges(bic_backward)
cat("Numero di archi nel grafo BIC:", num_edges_bic, "\n")
```

```
## Numero di archi nel grafo BIC: 79
```

- Il **grafo BIC** è più parsimonioso rispetto ad AIC, con un numero inferiore di archi.

Applicazione del GLASSO

Obiettivo

In questa sezione è stato costruito come base un grafo ottenuto tramite il **GLASSO (Graphical LASSO)**. L'obiettivo è stato quello di costruire modelli grafici gaussiani non orientati che identificano connessioni condizionali dirette tra le variabili, migliorando la comprensione delle dipendenze tra Mp,z e le altre variabili.


1. Risultati del GLASSO

```
lambda <- 0.1 # Valore di penalizzazione
glasso_result <- glasso(S_data, rho = lambda)
precision_matrix <- glasso_result$wi

# Creazione della matrice di adiacenza e del grafo GLASSO
threshold <- 0.1
adj_matrix <- (abs(precision_matrix) > threshold) * 1 # Soglia per sparsità
diag(adj_matrix) <- 0
glasso_graph <- graph_from_adjacency_matrix(adj_matrix, mode = "undirected")
V(glasso_graph)$name <- colnames(dataset_standardized)

plot_graph(glasso_graph, "Grafo stimato con GLASSO", "lightblue")
```

Grafo stimato con GLASSO



- **Struttura del grafo stimata:**

Il GLASSO (con penalizzazione $\lambda = 0.1$) ha evidenziato le **relazioni condizionali** tra le variabili, rappresentate nel grafo non orientato.

- Le connessioni tra **Mp** e **z** sono chiaramente presenti, suggerendo una **relazione diretta** condizionale tra queste due variabili.
- Alcune variabili, come **ROSAT**, **r_mag**, e le bande fotometriche **g_mag**, **z_mag** e **u_mag**, mostrano connessioni indirette con **Mp** e **z**.
- Un gruppo separato di variabili **sig_x_mag** non ha relazioni dirette con **Mp** e **z**, indicando una loro minore rilevanza rispetto al focus principale.

```
count_edges_glasso <- function(graph) {
  return(length(E(graph))) # Conta gli archi del grafo
}

# Conteggio degli archi nel grafo GLASSO
num_edges_glasso <- count_edges_glasso(glasso_graph)
cat("Numero di archi nel grafo GLASSO:", num_edges_glasso, "\n")

## Numero di archi nel grafo GLASSO: 22

find_max_cliques_glasso <- function(graph) {
  max_cliques <- max_cliques(graph)
  return(max_cliques)
}

max_cliques_glasso <- find_max_cliques_glasso(glasso_graph)

cat("Clique massimali nel grafo GLASSO:\n")

## Clique massimali nel grafo GLASSO:
print(max_cliques_glasso)

## [[1]]
## + 1/14 vertex, named, from calf046:
## [1] FIRST
##
## [[2]]
## + 2/14 vertices, named, from calf046:
## [1] ROSAT z
##
## [[3]]
## + 2/14 vertices, named, from calf046:
## [1] sig_u_mag u_mag
##
## [[4]]
## + 2/14 vertices, named, from calf046:
## [1] z Mp
##
## [[5]]
## + 2/14 vertices, named, from calf046:
## [1] z z_mag
##
## [[6]]
## + 3/14 vertices, named, from calf046:
## [1] Mp g_mag r_mag
##
## [[7]]
```

```
## + 4/14 vertices, named, from calf046:
## [1] sig_z_mag sig_g_mag sig_i_mag sig_r_mag
##
## [[8]]
## + 5/14 vertices, named, from calf046:
## [1] u_mag g_mag z_mag i_mag r_mag
```

Il **grafo GLASSO**, grazie alla penalizzazione applicata, seleziona un numero ridotto di connessioni (22 archi), concentrandosi sulle relazioni più significative e riducendo la complessità complessiva.

Interpretazione delle Clique

- **Clique 4 e Clique 5:** La presenza della variabile **z** insieme a **Mp** e **z_mag** indica che il **redshift** ha una relazione forte con la **magnitudine assoluta** e la sua banda associata **z_mag**.
- **Clique 6:** Le variabili **g_mag** e **r_mag** sono strettamente connesse a **Mp**, confermando il ruolo chiave di queste bande (banda verde-blu e rossa) nella previsione di **Mp**.
- **Clique 8:** Questo gruppo più ampio evidenzia una connessione forte tra le **bande magnitudinali** principali (**g_mag**, **r_mag**, **z_mag**, **i_mag**) e la variabile **u_mag**, indicando un legame importante nello spettro luminoso dei quasar.
- **Clique 7:** Le variabili **sig_x_mag** rappresentano gli errori associati alle bande e sono strettamente correlate tra loro, suggerendo un'associazione sistematica degli errori di misura.

L'analisi dei grafi mostra come il metodo **GLASSO**, rispetto ai modelli AIC e BIC, sia in grado di isolare e rappresentare relazioni **sparse** e significative tra le variabili.

La connessione diretta tra **Mp** e **z**, presente nelle clique identificate, conferma l'importanza della variabile redshift come predittore chiave della magnitudine assoluta nei quasar. Allo stesso tempo, le bande magnitudinali **g_mag** e **r_mag** emergono come variabili complementari nella descrizione di **Mp**.

Queste osservazioni sono coerenti con quanto riportato in letteratura astronomica, dove le bande fotometriche e il redshift giocano un ruolo cruciale nella modellazione delle proprietà dei quasar.

Creazione della Rete Bayesiana Orientata

Blacklist:

Una blacklist è stata costruita per escludere archi non rilevanti identificati nel grafo GLASSO. Questo ha consentito di evitare relazioni non significative durante l'apprendimento della rete Bayesiana.

```
get_edges_from_adj <- function(adj_matrix, nodes) {
  edges <- which(adj_matrix == 1, arr.ind = TRUE)
  data.frame(from = nodes[edges[, 1]], to = nodes[edges[, 2]])
}
nodes <- colnames(dataset_standardized)
edges_glasso <- get_edges_from_adj(adj_matrix, nodes)

# Creazione della blacklist
all_possible_edges <- expand.grid(from = nodes, to = nodes)
all_possible_edges <- subset(all_possible_edges, from != to)
blacklist <- setdiff(all_possible_edges, edges_glasso)
```

Rete Bayesiana:


Utilizzando il metodo **Hill Climbing** con criterio BIC, è stata costruita una rete Bayesiana orientata.

- L'orientamento degli archi indica la **direzione delle dipendenze** tra le variabili.
- La connessione diretta tra Mp e z è stata preservata, rafforzando l'importanza di z come predittore principale di Mp.
- Altre variabili, come g_mag, r_mag, e z_mag, hanno confermato che sono elementi intermedi che influenzano la relazione tra Mp e z.

```
hc_dag <- hc(dataset_standardized, blacklist = blacklist, score = "bic-g")

# Visualizza il DAG risultante
dag_adj <- amat(hc_dag)
qgraph(dag_adj,
  layout = "spring",
  labels = colnames(dataset_standardized),
  title = "Rete Bayesiana orientata dal GLASSO")
```

Rete Bayesiana orientata dal GLASSO



- Il **GLASSO** ha fornito una rappresentazione non orientata delle dipendenze condizionali, identificando le relazioni chiave tra variabili.
- La **Rete Bayesiana** ha aggiunto un **orientamento** alla struttura, consentendo di analizzare le dipendenze direzionali tra Mp, z e le variabili accessorie.
- La relazione tra Mp e z è stata validata come primaria e supportata da variabili intermedie come le bande fotometriche (g_mag, r_mag, z_mag).

Questa combinazione di tecniche ha consentito di **sintetizzare la complessità** delle dipendenze nel dataset, mantenendo il focus sulla relazione chiave tra Mp e z.

Analisi della Relazione tra Mp e z tramite Regressioni Lineari

Modello Completo

```
full_model <- lm(Mp ~ ., data = dataset_standardized)
summary(full_model)

##
## Call:
## lm(formula = Mp ~ ., data = dataset_standardized)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.6837 -0.1778  0.0231  0.1969  4.4121
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1.483e-15  6.079e-03   0.000 1.000000
## z            -8.678e-01  8.711e-03 -99.617 < 2e-16 ***
## u_mag        -7.762e-01  4.595e-02 -16.892 < 2e-16 ***
## sig_u_mag     1.336e-01  9.284e-03  14.388 < 2e-16 ***
## g_mag         1.099e+00  5.774e-02  19.036 < 2e-16 ***
## sig_g_mag    -1.492e-01  1.410e-02 -10.588 < 2e-16 ***
## r_mag         7.432e-01  8.037e-02   9.247 < 2e-16 ***
## sig_r_mag    -3.526e-01  3.064e-02 -11.507 < 2e-16 ***
## i_mag        -1.979e-01  5.218e-02  -3.793 0.000151 ***
## sig_i_mag     1.385e-01  2.558e-02   5.414 6.55e-08 ***
## z_mag        -6.661e-01  4.212e-02 -15.814 < 2e-16 ***
## sig_z_mag     4.164e-01  1.543e-02  26.978 < 2e-16 ***
## FIRST        -4.749e-02  6.315e-03  -7.520 6.83e-14 ***
## ROSAT        -9.749e-02  7.467e-03 -13.055 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3704 on 3699 degrees of freedom
## Multiple R-squared:  0.8633, Adjusted R-squared:  0.8628
## F-statistic: 1796 on 13 and 3699 DF, p-value: < 2.2e-16
```

Nel modello completo sono state incluse **tutte le variabili indipendenti** per spiegare la variabilità della variabile dipendente **Mp**. Questo modello ha mostrato un **R-squared pari a 86.33%**, indicando che l'86.33% della variabilità di **Mp** è spiegata dalle variabili indipendenti selezionate.

Questo modello ha mostrato che molte variabili contribuiscono a spiegare **Mp**, ma la complessità del modello rende necessaria una selezione delle variabili più rilevanti.

Modello Ridotto

```
reduced_model <- lm(Mp ~ z + g_mag + r_mag + ROSAT + z_mag + i_mag + u_mag + sig_u_mag,
                    data = dataset_standardized)
summary(reduced_model)

##
## Call:
## lm(formula = Mp ~ z + g_mag + r_mag + ROSAT + z_mag + i_mag +
##      u_mag + sig_u_mag, data = dataset_standardized)
```

```
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.8473 -0.2008  0.0169  0.2092  5.3591
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1.498e-15  6.692e-03   0.000      1
## z            -8.502e-01  9.435e-03 -90.112 < 2e-16 ***
## g_mag        1.152e+00  6.321e-02  18.220 < 2e-16 ***
## r_mag        8.278e-01  8.829e-02   9.375 < 2e-16 ***
## ROSAT       -1.287e-01  8.027e-03 -16.030 < 2e-16 ***
## z_mag       -4.964e-01  4.586e-02 -10.826 < 2e-16 ***
## i_mag       -2.589e-01  5.728e-02  -4.520 6.38e-06 ***
## u_mag       -9.685e-01  4.951e-02 -19.560 < 2e-16 ***
## sig_u_mag    1.847e-01  9.870e-03  18.714 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4078 on 3704 degrees of freedom
## Multiple R-squared:  0.8341, Adjusted R-squared:  0.8337
## F-statistic: 2328 on 8 and 3704 DF,  p-value: < 2.2e-16
```

Un'analisi successiva ha portato a un modello più parsimonioso, in cui sono state selezionate solo le variabili più significative, ovvero:

- **z**
- **g_mag**
- **r_mag**
- **ROSAT**
- **z_mag**
- **i_mag**
- **u_mag**
- **sig_u_mag**

Il **R-squared** è risultato **83.41%**, molto vicino al modello completo, ma con un numero ridotto di predittori. Questo dimostra che le variabili selezionate sono sufficienti per spiegare la variabilità di Mp.

Anche in questo modello, **z** continua ad avere un **effetto negativo forte e significativo** su Mp.

Modello z-g-r

```
zgr_model <- lm(Mp ~ z + g_mag + r_mag, data = dataset_standardized)
summary(zgr_model)
```

```
##
## Call:
## lm(formula = Mp ~ z + g_mag + r_mag, data = dataset_standardized)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.7861 -0.2248  0.0358  0.2304  6.4630
```

```
##
## Coefficients:
##           Estimate Std. Error  t value Pr(>|t|)
## (Intercept) -5.478e-16  7.421e-03    0.000      1
## z           -8.699e-01  7.547e-03 -115.258 < 2e-16 ***
## g_mag        6.831e-01  4.818e-02   14.177 < 2e-16 ***
## r_mag       -2.915e-01  4.808e-02   -6.062 1.48e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4522 on 3709 degrees of freedom
## Multiple R-squared:  0.7957, Adjusted R-squared:  0.7955
## F-statistic: 4815 on 3 and 3709 DF,  p-value: < 2.2e-16
```

Un'ulteriore riduzione delle variabili ha permesso di includere solo le tre variabili più rilevanti:

- **z**,
- **g_mag**,
- **r_mag**.

Questo modello ha ottenuto un **R-squared pari a 79.57%**, confermando che **z** da sola o insieme a poche variabili è sufficiente per spiegare gran parte della variabilità di **Mp**.

In particolare:

- **z** mantiene un **forte effetto negativo** su **Mp**, suggerendo che all'aumentare del redshift (**z**), la magnitudine assoluta **Mp** diminuisce ulteriormente (indicando oggetti più luminosi).

Modello con Solo Mp e z

```
z_model <- lm(Mp ~ z, data = dataset_standardized)
summary(z_model)
```

```
##
## Call:
## lm(formula = Mp ~ z, data = dataset_standardized)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.6939 -0.3538  0.0807  0.4029  1.8241
##
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept) -6.797e-16  9.818e-03    0.00      1
## z           -8.014e-01  9.819e-03  -81.61 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5982 on 3711 degrees of freedom
## Multiple R-squared:  0.6422, Adjusted R-squared:  0.6421
## F-statistic: 6661 on 1 and 3711 DF,  p-value: < 2.2e-16
```

Per convalidare ulteriormente l'importanza della variabile **z**, è stata effettuata una regressione lineare semplice considerando **Mp** come variabile dipendente e **z** come unico predittore.

Il risultato ha mostrato un **R-squared pari a 64.22%**, confermando che **z da sola spiega oltre il 64% della variabilità di M_p** .

L'effetto negativo di **z** su **M_p** è rimasto evidente, con un coefficiente significativo. Questo indica che all'aumentare di **z**, la magnitudine assoluta **M_p diminuisce**, il che corrisponde a una maggiore luminosità dei quasar osservati.

Conclusioni

Dall'analisi finale emerge chiaramente che la variabile **z** ha un impatto predominante su **M_p** .

L'aumento del redshift è associato a una **diminuzione di M_p** , che implica un incremento della luminosità dei quasar. Sebbene altre variabili come **g_mag** e **r_mag** contribuiscano a spiegare ulteriormente la variabilità di **M_p** , **z** rimane il predittore principale e chiave per comprendere il comportamento della magnitudine assoluta.

Questa relazione è stata osservata e validata attraverso modelli con complessità decrescente, confermando l'importanza fondamentale di **z** nello studio della luminosità dei quasar.